



UNIVERSITÉ
DE LORRAINE



Lothaire

LICENCE ASRALL

Analyse de logs avec ELK

Auteur :

François DUPONT

Tuteur :

Vincent DELOVE



elastic



Compilé le 11 juin 2015

Remerciements

Remerciment 1

Remerciment 2

Remerciment 3

Table des matières

I	Introduction	4
0.1	Problématique	5
1	Environnement	6
1.1	Sous Direction des Infrastructures	6
1.2	Environnement de travail	6
2	La gestion de logs	7
3	Les clusters	8
4	MoM	9
5	Gestion de projet	10
5.1	Nos objectifs	10
6	Présentation des notions	11
7	Définitions	12
II	Les logiciels	13
8	Logstash	14
8.1	Présentation de Logstash	14
8.2	Installation	16
8.3	Fonctionnement	18
8.4	Grammaire et conjugaison	18
8.5	Utilisation	22
8.6	Mon serveur central	23
8.7	Monter à l'échelle	23
9	Elasticsearch	24
9.1	Présentation de Elasticsearch	24
9.2	Installation	25
9.3	Sense	25
9.4	La théorie	27
9.5	L'infrastructure	27

9.6 Les API Elasticsearch	29
9.7 Le mapping et l'analyse	33
10 Kibana	35
10.1 Qu'est ce que Kibana	35
10.2 Installation de Kibana	35
10.3 Utilisation de Kibana	36
 III Synthèse et conclusion	 46
11 Fonctionnement général	47
12 Évolutions possible	48
12.1 Monitoring	48
12.2 Sécurité	48
13 Conclusion	49
 IV Annexes	 50
14 Sources/Webographie/Bibliographie	51
15 Code Source et scripts	53

Première partie

Introduction

0.1 Problématique

La gestion de logs est une problématique commune à presque tous les services informatique, tous les fournisseurs de services et plus globalement, toutes personnes gérant une infrastructure informatisée.

Les logs sont précieux car ils sont un des éléments indispensable au dépanage, au monitoring, à l'anticipation de problèmes inhérent à l'exploitation d'une infrastructure informatique.¹ *De nombreuses structures continuent encore aujourd'hui d'analyser plus ou moins "manuellement" leurs logs, qu'ils proviennent de hardware, ou de software.*

L'objectif de ce projet est de répondre à la problématique de la gestion et de l'analyse de log, en utilisant la stack ELK². Dans ce rapport nous expliquerons de façon plus précise en quoi consiste la gestion de log, les fonctions et fonctionnement des outils dont nous ferons usage, enfin, nous détaillerons notre architecture et ses évolutions possibles.

1. terme volontairement très vaste

2. Elasticsearch Logstash Kibana

Chapitre 1

Environnement

1.1 Sous Direction des Infrastructures

1.2 Environnement de travail

Chapitre 2

La gestion de logs

La gestion des logs est un problème presque aussi vieux que l'informatique. Au commencement

La tendance est cependant (et depuis longtemps) à la centralisation de ces fichiers afin de faciliter leur accès et leur analyse ultérieure. Cela permet également une sauvegarde plus facile de ces derniers dans le cas où cela est nécessaire. Il est fréquent d'avoir des scripts analysant quotidiennement ces logs afin de pouvoir détecter un comportement suspect.

Chapitre 3

Les clusters

Chapitre 4

MoM

Chapitre 5

Gestion de projet

5.1 Nos objectifs

Chapitre 6

Présentation des notions

Chapitre 7

Définitions

Deuxième partie

Les logiciels

Chapitre 8

Logstash



8.1 Présentation de Logstash

Logstash permet de traiter et/ou de transférer des données, en masse. Dans notre projet, nous l'utiliserons essentiellement en conjonction avec Elasticsearch en utilitaire de sorti. Cependant, et comme le montre la liste des ses abondants plugins d'output, Logstash est capable de fonctionner avec de nombreux autres logiciels.

8.1.1 Pourquoi Logstash ?

Bien qu'un administrateur système compétent soit capable d'analyser de façon rapide et efficace les logs d'une machine (à l'aide de `perl+awk+sed+tail+grep`), cette méthode est fastidieuse. De plus, face à des dizaines/milliers de machines (virtuelles aussi), cette méthode n'est plus applicable, elle ne peut pas passer à l'échelle. Il est actuellement fréquent (cloud, applications multicouche, ...) que les logs d'une seule machine ne suffise plus à diagnostiquer le problème auquel on est confronté.

8.1.2 Fonctionnement interne

L'utilisation de logstash est un pipeline qui s'articule autour de 3 *blocs* également appelés *stages* (phase).

- Le bloc : *Inputs* génère des événements à partir des informations reçues par logstash en entrée.
- Le bloc : *Filters* modifie, manipule, ces événements dans logstash
- Le bloc : *Outputs* envoie les événements de logstash vers leur prochaine destination.

Cette façon de fonctionner peut faire penser à *iptables*.

Logstash est un logiciel développé en Jruby¹ (Jruby est en faite une implémentation de ruby 1.8 en Java qui était à l'époque plus rapide que ruby "seul"). Le passage d'une phase à l'autre est implémenté via les *SizedQueue* de ruby. Elles sont dimensionnées pour contenir 20 éléments², ce n'est pas paramétrable sans modifier le code source, c'est un choix délibéré. Ces queues ne sont pas conçues pour stocker des données à long terme. On verra plus tard que ce la justifie l'utilisation d'un *buffer*, comme *Redis*³.

Chaque bloc est composé d'une multitude de plugins. Ce sont des modules indépendants qui peuvent également fonctionner en conjonction les uns des autres.

Il est, par exemple, possible de configurer le bloc *inputs* pour utiliser plusieurs fois le plugin "file" (on imagine pour des cas d'utilisation différents) et de se servir dans le même temps d'un autre plugin du bloc *inputs* : *stdin* qui prendra typiquement en entrée le clavier.

Il est possible d'implémenter de nouveaux plugins en ruby afin de les ajouter à notre logstash.

Il existe également un *pseudo-bloc* qui peut s'insérer dans les autres, ce bloc, *codec* permet la de gérer la *représentation des données* c'est à dire qu'un codec est capable de lire ou d'écrire dans une syntaxe particulière comme par exemple *rubydebug*, *collectd*, ou, bien plus intéressant pour nous, *netflow*.

Tolérance de pannes

Vos logs sont **importants**, c'est la raison d'être de Logstash, il ne souhaite pas que vous en perdiez le moindre à cause d'un problème réseau ou d'une défaillance quelconque rendant la destination indisponible. Lors d'une indisponibilité, les plugins *outputs* tentent de renvoyer les événements vers leur destination. Si ce n'est pas possible le plugin arrête de lire sa queue tant que le message n'a pas pu être envoyé. Par effet domino, une fois la queue *filtre* => *output* remplie, le bloc filtre, ne pouvant plus envoyer de nouveaux messages à la queue *FO*. Le plugin du bloc filtre va également tenter d'envoyer ses messages, et refuser en attendant de lire les nouveaux arrivant dans la queue *input* => *filtre*. Si cette dernière venait à se remplir c'est le Logstash tout entier qui refuserait de traiter de nouvelles informations. Dans le meilleur des mondes, les expéditeurs de données se comporteraient comme logstash et attendraient patiemment que le problème se résolve, malheureusement cela n'est pas toujours possible, particulièrement dans nos problématiques d'où l'im-

1. sauf mention contraire, on supposera dans ce rapport que logstash est développé en ruby
2. appelés messages lorsqu'on parle de queues, on parle bien ici des **événements** logstash
3. voir la sous partie sur la tolérance de pannes ainsi que le chapitre consacré à Redis

portance d'un Redis en amont (ou en aval) afin de faire tampon. ⁴

Multithread

Attention ces informations sont pour le moment, , correctes mais sont amenées à changer, notamment concernant les outputs.

Chaque plugin input utilise un thread, cela permet d'éviter les engorgements si certaines entrées sont plus longues à traiter que d'autres.

En le bloc filtre entier n'utilise par défaut qu'un seul thread, mais il est possible d'augmenter le nombre de threads affectés au traitement des filtres avec le flag `-w` lors du démarrage de Logstash.

À l'heure actuelle le bloc output de logstash ne peut utiliser qu'un seul thread. Il lit donc sa queue de façon séquentielle.

8.2 Installation

Sur Debian jessie il n'existe pas de paquet officiel logstash maintenu. Il existe en revanche un paquet tiers ⁵ fourni par l'éditeur du logiciel. Le dit paquet n'est pas de très bonne facture puisqu'il nécessite l'ajout de dépendances manuelles ⁶ ainsi qu'un rechargement de la configuration des services : `systemctl daemon-reload`.

Les dépendances nécessaires sont `jruby` et `openjdk-7-jre`, les mêmes que pour elasticsearch.

Une autre manière de réaliser l'installation est d'ajouter les dépôts logstash à `/etc/apt/source.list.d/logstash.list.d/logstash.list`

```
1 deb https://packages.elasticsearch.org/logstash/1.4/debian stable  
main
```

et évidemment la clef qui va bien ⁷

```
1 wget -qO - https://packages.elasticsearch.org/GPG-KEY-elasticsearch |  
sudo apt-key add -
```

8.2.1 Configurations

Il est d'usage dans une installation *propre* de créer un utilisateur spécifique à notre utilisation. C'est également le cas dans notre paquet. L'administrateur système doit donner à cet utilisateur, nouvellement créer les droits nécessaire pour qu'il puisse faire son travail correctement. Dans le cadre de l'analyse de log faire de l'utilisateur logstash un membre du groupe `adm`, le groupe d'administration de Debian lui permettra par exemple d'avoir accès en lecture à la plupart des fichiers de `/var/log/`.

4. Il existe d'autres outils que Redis, (dont ce n'est pas la fonction principale) pour réaliser ce travail, ils sont plus adapté mais aussi moins documentés dans leur utilisation avec logstash.

5. https://download.elastic.co/logstash/logstash/packages/debian/logstash_1.4.2-1-2c0f5a1_all.deb

6. `wget` paquet, `dpkg -i` paquet, `apt-get install -f`

7. permet d'authentifier les paquets téléchargés (cf :SecureApt)

Set Capabilities

Cependant cette façon de faire peut ne pas être suffisante. Notre utilisation de logstash consiste, entre autre, à centraliser les logs. Ces derniers sont généralement envoyés par l'intermédiaire de syslog (RFC 5244). Par défaut syslog utilise le port 514, ce port est inférieur à 1024, et donc *privilegié*. Aussi seul *root* à le droit d'écouter ces ports. Ajouter notre utilisateur logstash au groupe root enlèverait le bénéfice de sécurité obtenu en isolant les utilisateurs en fonction de leurs besoins. Nous allons plutôt utiliser les *capabilities*⁸ et la commande *setcap*⁹

```
1 setcap cap_net_bind_service=+epi /usr/lib/jvm/java-7-openjdk-amd64/  
   jre/bin/java  
2 setcap cap_net_bind_service=+epi /usr/lib/jvm/java-1.7.0-openjdk-  
   amd64/jre/bin/java
```

qui permettent à un processus (thread en faite) de ne pas se soumettre à certaines vérifications de sécurité du noyau.

cap_net_bind_service permet à un utilisateur non privilégié (non root) d'écouter sur les ports privilégiés.

Les informations concernant les autres capabilities existants sont disponible dans la page de manuel correspondante : *man capabilities*.

=+epi signifie que l'on ajoute une *capability* à un fichier. Plus précisément **=+** signifie que l'on écrase les droits précédents pour les remplacer par les nouveaux. **e**, **p** et **i** sont la gradation de droits que l'on peut attribuer à un fichier avec les capabilities¹⁰.

- **effective** : indique si la capability est utilisé actuellement
- **permitted** : définit quelles capabilities sont autorisé pour un processus donné
- **inherited** : permet de transmettre la capability à un autre programme

Note : par défaut, changer le propriétaire d'un fichier de root, à non root enlève les capabilities associées à ce dernier¹¹.

Pour vérifier les *capabilities* d'un binaire on utilise la commande *getcap*.

```
1 getcap /bin/ping  
2 /bin/ping = cap_net_raw+ep
```

Pour les enlever les capabilities il faut utiliser la commande suivante.

```
1 setcap cap_net_bind_service=-epi /usr/lib/jvm/java-1.7.0-openjdk-  
   amd64/jre/bin/java
```

Enfin, il est possible, de donner le droit à un utilisateur non root, l'autorisation de modifier certaines capabilities. Pour ce faire, il faut modifier le fichier

/etc/security/capability.conf.

8. <http://man7.org/linux/man-pages/man7/capabilities.7.html>

9. <https://github.com/elastic/logstash/issues/1587>

10. <https://www.kernel.org/pub/linux/libs/security/linux-privs/kernel-2.2/capfaq-0.2.txt>

11. <http://stackoverflow.com/questions/17743062/changing-user-ids-for-assigning-additional-capabilities>

8.3 Fonctionnement

Logstash peut s'intégrer dans une architecture simple ou très compliquée, en fonction du cas il peut être utilisé dans plusieurs modes.

8.3.1 La base

8.4 Grammaire et conjugaison

8.4.1 Généralités

Dans cette section nous allons brièvement expliquer le fonctionnement de la syntaxe du fichier de configuration de Logstash.¹²

Le ou les fichiers de configuration comportent deux ou trois parties, représentant les blocs dont nous avons parlé au préalable. Le bloc *filter* est optionnel et il est important de noter que, si il est possible de répartir sa configuration dans plusieurs fichiers, cette dernière sera concaténer, attention aux boucles infinies dans ce cas là.

```
1 input {
2     stdin{}#ceci est un plugin
3 }
4
5 #filter {
6 #}#on peut également commenter en fin de ligne
7
8 output {
9     stdout{}#ceci est un autre plugin
10 }
```

Listing 8.1 – Configuration minimale

Ici on constate l'utilisation des plugins stdin et stdout, stdin. Comme leur nom et leur emplacement dans le fichier de configuration peut le laisser supposer. Ici Logstash collecte en entrée tout ce qui vient de l'entrée standard, typiquement le clavier, et l'envoi sur la sortie standard, typiquement, un terminal. Pour pouvoir recevoir l'output, il est d'ailleurs conseillé d'utiliser, le flag -f et de ne pas lancer logstash en mode daemon.

Dans ce second exemple, plus complexe, nous allons présenter une utilisation plus vaste des plugins et la logique sous-jacente à leur utilisation.

```
1 #mail.conf
2 input {
3     file {
4         path => ["/home/fdupont/testmail"]
5     }
6 }
7
8 filter{
9     throttle{
10         before_count => 2
11         after_count => 4
12     }
13 }
```

12. <http://logstash.net/docs/1.4.2/configuration>

```
12     period => 120
13     key => "%{message}"
14     add_tag => "contenu"
15 }
16 }
17
18 output {
19     stdout{ }
20     if "contenu" not in [tags]{
21         email{
22             to => "fdupont@localhost"
23             from => "logstash@%{host}"
24             subject => "%{message}"
25             body => "Ceci_est_un_test_sur_l'hote_%{host}\n_avec_pour_
                message_:_%{message}"
26         }
27     }
28 }
29
30 #shipping.conf
31 input {
32     file {
33         path => ["/var/log/secure", "/var/log/messages", "/var/log/*.
                log", "/var/mail/fdupont"]
34         exclude => ["*.gz"]
35     }
36     file {
37         path => ["/var/mail/ldidry"]
38     }
39 }
40
41
42 output {
43     stdout{ }
44     redis {
45         host => "100.127.255.1"
46         data_type => "list"
47         key => "logstash"
48     }
49 }
```

Listing 8.2 – Infinite loop

Cet exemple de code ne doit pas être utilisé : c'est une boucle infinie. Il permet en revanche d'expliquer de nombreux points de fonctionnement de la syntaxe du fichier de configuration de Logstash. Ce code représente en fait **2 fichiers**, mail.conf et shipping.conf, tout deux situés dans le répertoire par défaut des fichiers de configuration de Logstash `/etc/logstash/conf.d/`. Ils sont lus par ordre alphabétique et concaténés (comprendre que les inputs ainsi que les outputs sont fusionnés, il faut donc être rigoureux dans leur écriture afin de ne pas créer d'effets de bord indésirables). Une bonne pratique consiste, à utiliser la convention de nommage suivante : *00-description*, *01-description* etc ...

Chacun possède un bloc input, output et l'un d'entre eux : filter. Dans chacun des blocs on trouve un ou plusieurs **plugins** comme email, file, redis ou d'autres. Chacun de ces plugins possède son propre paramétrage, réglable au travers de directives, mais avec une syntaxe commune.

```
1 directive => int
2 directive => "string"
3 directive => ["membre", "de", "l'array"]
```

Listing 8.3 – Syntaxe

La plupart des directives de plugins se comportent ainsi, pas toutes, nous verrons quelques exemples dans des configurations plus avancées. Dans tout les cas est indispensable de référer à la documentation pour toute primo utilisation d'un plugin.

Comme montré dans le code 8.3 il est également possible d'utiliser des structures conditionnelles (les if, else, else if, en faite). De nombreux opérateurs sont également supportés : ==, !=, <, >, <=, >=, mais aussi les expressions régulières (syntaxe ruby) =~, ~! et enfin : in, not in, and, nand, or, xor et !.

Dans notre exemple de code 8.2, la structure conditionnelle est utilisé pour faire le trie en utilisant les *tags*.

Il est à noter également les directives **path** disponibles par exemple dans le plugin file, prennent en compte le globbing et le globbing récursif (**le/chemin/*/*.log**).

Autopsie d'une la boucle infinie

La configuration 8.2, qui ne fonctionne pas correctement n'a pas été mise là par hasard. Cette erreur, permet de bien comprendre le fonctionnement des fichiers de configuration de Logstash.

Rappels : Il y a dans cette configuration, 2 fichiers de configuration. Les fichiers, sont concaténés au lancement de Logstash de telle sorte que virtuellement cela donnerait un résultat similaire à :

```
1 #mail.conf
2 input {
3   file {
4     path => ["/home/fdupont/testmail"]
5   }
6   file {
7     path => ["/var/log/secure", "/var/log/messages", "/var/log/*.log", "/var/mail/fdupont"]
8     exclude => ["*.gz"]
9   }
10  file {
11    path => ["/var/mail/ldidry"]
12  }
13 }
14
15 filter{
16   throttle{
17     before_count => 2
18     after_count => 4
19     period => 120
20     key => "%{message}"
21     add_tag => "contenu"
22   }
23 }
24
25 output {
26   stdout{ }
27   if "contenu" not in [tags]{
28     email{
29       to => "fdupont@localhost"
30       from => "logstash@%{host}"

```

```
31         subject => "%{message}"
32         body => "Ceci_est_un_test_sur_l' hote_%{host}\n_avec_pour_
           message_:_%{message}"
33     }
34 }
35 redis {
36     host => "100.127.255.1"
37     data_type => "list"
38     key => "logstash"
39 }
40 }
```

Listing 8.4 – Infinite loop concaténé

Ici le problème semble plus évident l'output et l'input sont "liés". Des messages peuvent être détectés et envoyés par mail à l'adresse `fdupont@localhost` (soit l'équivalent de `/var/mail/fdupont`). Ce fichier est également écouté, ainsi que la plupart de fichiers de logs, voilà la source des boucles infinies, assez facilement reproductible si l'on n'est pas suffisamment rigoureux, et surtout si l'on travail sur plusieurs fichiers à la fois.

L'autre erreur majeur de ce fichier se situe à la ligne 27. Si le terme contenu n'est pas présent dans "tags" alors on envoie un mail. Le fonctionnement est l'inverse de celui suggérer par throttle. Ici un mail est envoyé dès qu'un événement se produit dans un fichier de log. Ce mail envoyé dans `/var/mail/fdupont` sera renvoyé dans cette même adresse, le contenu de l'événement se modifiera en permanence puisque le message sera encapsulé dans son prédécesseur ...

8.4.2 Expressions régulières et patterns

Les expressions régulières utilisées par Logstash dans le plugin grok utilisent le moteur Oniguruma dont les spécifications sont disponibles à cette adresse ¹³. Ruby n'utilise plus Oniguruma depuis la version 2.0 mais son fork Onigmo ¹⁴. Mais cette évolution ne s'applique pas à Logstash puisque ce dernier est codé en Jruby.

Les expressions régulières de Grok

Ce moteur permet des manipulations avancées d'expressions régulières, ce n'est pas l'objet de ce projet de les présenter. Nous nous contenterons simplement d'utiliser des syntaxes assez classiques d'expressions régulières à l'exception des named groups. Qui permettent avantageusement de ne pas utiliser les patterns, ou plutôt d'en créer de nouveaux sans modifier les fichiers de Logstash. (Grok est le plugin dont on se servira le plus avec Logstash c'est pour cela que nous prenons le temps de présenter son système d'expression régulière)

```
1 (?<nom_du_champ>Pattern)
2 (?<username> [a-zA-Z0-9._-]+)
```

Listing 8.5 – Named group

13. <http://www.geocities.jp/kosako3/oniguruma/doc/RE.txt>, si des symboles ¥ apparaissent vous avez probablement un problème d'UTF8 sur votre navigateur, ils correspondent à des \

14. dixit Wikipédia <https://en.wikipedia.org/wiki/Oniguruma>

Grok créera rangera automatiquement une chaîne de caractère satisfaisant la contrainte `/[a-zA-Z0-9._-]+/` dans un champ `username`. Ce champ pourra être réutiliser ultérieurement par Logstash ou même Elasticsearch.

Les patterns

Logstash mets en place un système très utile et très facile à utiliser de patterns (motifs), ces patterns correspondent à des mots clefs représentant des expressions régulières ou bien des concaténations d'expressions régulières ou de patterns.

La compréhension des patterns est simple et presque instantané si l'on connaît les expressions régulières.

```
1 CISCOMAC (?:(?:[A-Fa-f0-9]{4}\.){2}[A-Fa-f0-9]{4})
2 WINDOWSMAC (?:(?:[A-Fa-f0-9]{2}-){5}[A-Fa-f0-9]{2})
3 COMMONMAC (?:(?:[A-Fa-f0-9]{2}:){5}[A-Fa-f0-9]{2})
4
5 MAC (?:%{CISCOMAC}|%{WINDOWSMAC}|%{COMMONMAC})
```

Listing 8.6 – Exemple de définition et d'utilisation de Patterns

Grok peut également utiliser ces patterns mais leur fonctionnement est général dans Logstash. On comprends bien dans le code précédent le fonctionnement des patterns : qui est très similaire à celui des *named groups* : définition d'un nom, expression régulière associé. On les utilise en invoquant leur nom entouré par % Il sont utilisable ensemble comme dans l'exemple ci-dessus avec les adresses MAC, ou (beaucoup) plus bas dans l'explication du fonctionnement de l'architecture.

Nous n'avons pas créer de nouveaux patterns pour notre projet et préférer l'utilisation des expressions régulières. Cela reste cependant possible en modifiant les fichiers paramétrant ces patterns. Ils sont par défaut situés dans `/opt/logstash/patterns`.

8.4.3 Les flags

Les *flags* sont les noms donnés aux paramètres que l'on peut donner au binaire de Logstash.

- `-f` : file, désigne le fichier de configuration à utiliser
- `-e` : permet d'utiliser une chaîne de caractères (depuis la console) pour pour configurer Logstash, à utiliser pour faire des tests de configuration simple.
- `-w` : filterworkers, comme expliqué plus haut, permet d'affecter plusieurs threads à la gestion des filtres. (par défaut 1)
- `-configtest` : associé à `-f path/to/conffile` vérifie la syntaxe du fichier de configuration.

Par défaut Logstash utilisera les fichiers de configuration présents dans `/etc/logstash/conf.d/`, ils seront ouverts par ordre alphabétique.

8.5 Utilisation

Nous allons enfin discuter de la façon dont on peut utiliser Logstash On peut utiliser Logstash de plusieurs façons, de manière plus ou moins complexe en fonction

de nos besoins et de notre infrastructure. La configuration la plus simple consiste à

8.6 Mon serveur central

8.7 Monter à l'échelle

Chapitre 9

Elasticsearch



9.1 Présentation de Elasticsearch

Elasticsearch est moteur de recherche et d'analyse en temps réel. Il permet l'exploration de données de façon très rapide par des recherches, que ce soit par des recherches fulltext, ou bien des recherches structurées.

Elasticsearch est depuis peu développé par la société *Elastic*. C'était, à la base, un projet du développeur Shay Banon, qui souhaitait concevoir une API simplifiée pour la bibliothèque de moteur de recherche : Apache Lucene¹.

Elasticsearch et la stack ELK est en passe de devenir un standard dans l'industrie. En effet le logiciel à une utilisation assez versatile, de l'aide à la prise de décision en temps réelle à l'analyse de code source. Et à l'heure actuelle, la capacité à exploiter les masses de données et de méta données accumulées chaque jour devient un enjeu économique majeur (mais pas seulement ...). Enfin l'un des principaux atouts d'Elasticsearch réside dans son aptitude à pouvoir passer à l'échelle simplement.

Attention, ce chapitre ne sera qu'une présentation très succincte des possibilités du logiciel Elasticsearch, tout détailler nécessiterait sans doute des milliers de pages, le résumé officiel² en fait déjà plus de 950 ...

1. Page du projet Lucene <https://lucenenet.apache.org/>

2. Elasticsearch : The Definitive Guide, disponible chez Pearson et Github <https://github.com/elastic/elasticsearch-definitive-guide>

9.2 Installation

Avant même de regarder les différentes dépendances nécessaires à l'utilisation de Elasticsearch il est recommandé de vérifier que l'on utilise bien la même version que son compère Logstash (vérifier la compatibilité dans la documentation si les versions de Logstash et Elasticsearch ont un numéro différent).

Son installation est sensiblement la même que son comparse logstash puisque ce logiciel nécessite également l'installation des dépendances *jruby* et *openjdk-7-jre* à noter qu'il fonctionne également sur *openjdk-8-jre*.

Là aussi les paquets debian officiels n'existant pas on utilisera celui fourni par elastic.co. Et ici aussi le paquet est un peu approximatif puisqu'il faut rajouter certains chemins, et ajouter des droits.

9.2.1 Configuration de base

Acompléter et revoir p24-26 test

9.3 Sense

Sense est un module chrome développé par Boaz Leskes, il sert de front-end à Elasticsearch. Le développement (public) de ce module est maintenant arrêté. Il fait parti de *Marvel* le logiciel de monitoring et d'optimisation, vendu³ par la société *elastic*.

9.3.1 Installation

Installer ce logiciel est simple comme installer une extension Chrome⁴ tierce. Tout d'abord : récupérer le module à l'adresse <https://github.com/bleskes/sense> en utilisant par exemple :

```
1 git clone https://github.com/bleskes/sense.git
```

Il suffit ensuite de l'activer dans chromium :
chrome ://extension => Developer mode => Load unpacked extension.




FIGURE 9.1 – Plugin Sense installé dans chromium

Et voilà ! (avec un accent anglais)

3. voir bas de page : <https://www.elastic.co/products/marvel/signup.html>

4. testé sur chromium

9.3.2 Utilisation de Sense

L'utilisation de Sense est assez simple via son interface :




FIGURE 9.2 – Vue générale de Sense

La difficulté se situe évidemment plutôt du côté de l'appréhension, la configuration et l'optimisation de Elasticsearch.

Nous allons avec l'image ci-dessous 9.3.2 brièvement expliquer le fonctionnement de Sense




FIGURE 9.3 – Zoom sur les fonctionnalités de Sense

Le formulaire **Server** situé en haut correspond à l'adresse et au port d'écoute de l'instance Elasticsearch sur laquelle on souhaite travailler.

Le panneau de gauche correspond au **panneau de requête**. On utilise l'api REST d'Elasticsearch pour envoyer des requêtes (recherches, modification etc, point sur l'API prévu ultérieurement). Il est à noter que le panneau de gauche est doté d'une autocomplétion pour les fonctions et configurations standards dans Elasticsearch.

Le panneau de droite est le **panneau de réponse** aux requêtes. Les informations nous parviennent en JSON.

9.4 La théorie

9.4.1 Approximation et comparaison avec le modèle relationnel

La comparaison entre Elasticsearch et une base de données n'est pas forcément heureuse, c'est un moteur de recherche (d'indexation). Il utilise donc la notion d'index qu'on peut cependant assez facilement comparer au modèle relationnel.

Elasticsearch s'organise autour d'index que l'on peut comparer aux bases (de données) dans le modèle relationnel, un index peut utiliser plusieurs types (dans notre projet nous aurions pu différencier les logs firewall des logs *states* en utilisant les types), les types s'apparentent aux tables dans le modèle relationnel. Chaque enregistrement d'Elasticsearch est effectué sous forme document. Les documents (qui ont un type, éventuellement type par défaut), un document peut être comparé à une ligne, ou un enregistrement. Ces lignes sont constitués de colonnes, appelées champs (ou fields) dans Elasticsearch.

NEED image

9.5 L'infrastructure

9.5.1 Le tuning

Voici quelques conseils qui sont applicables pratiquement dans toutes les situations pour une utilisation optimale de Elasticsearch.

Ne pas utiliser la swap

Il est très fréquent (et souvent nécessaire) de formater une partition de swap pour que le système puisse optimiser son fonctionnement. C'est très pratique pour ne pas saturer la mémoire RAM de nos machines de bureau, notamment quand on voit la consommation pantagruélique de certains navigateurs internet récents. Les fichiers qui ne sont susceptibles de ne pas être utilisés avant un long moment sont parfois stockés sur le disque dur afin de libérer de l'espace pour d'autres applications, la swap est également utilisée lorsque l'on met un ordinateur en veille ...

La situation n'est pas la même sur un serveur. Ici nous sommes relativement maître de notre environnement, et de plus nous voulons que le service Elasticsearch soit le plus vélocité possible, pour se faire il faut au contraire l'empêcher au maximum d'utiliser la partition de swap (forcément plus lente).

Il existe plusieurs façons de faire (y compris ne pas utiliser de partition de swap) celle que j'ai choisie d'utiliser est de modifier la variable **vm.swapiness** dans le fichier **/etc/sysctl.conf**. La *swapiness* représente le pourcentage de mémoire RAM restant à partir duquel on commence à envoyer de l'information en swap.

```
1 vm.swapiness = 2
2 swapoff -a
3 swapon -a
```

Listing 9.1 – Configuration swapiness

Il existe deux méthodes pour que le changement de swapiness soit pris en compte : redémarrer la machine ou bien désactiver puis réactiver la swap, via les commandes `swapon`, `swapoff`. Utiliser la commande `swapoff` est également une mesure radicale à notre problème.

Utiliser une quantité de RAM raisonné

Elasticsearch est limité par Java. Avant de parler de ces limites, il faut rappeler que Elasticsearch est un front-end à Apache Lucene. Lucene est conçu pour tirer parti très efficacement du cache des système de fichiers (probablement ext4 si vous utilisez Debian), qui sont en définitif, gérés par le noyau⁵. Il est conseillé par la documentation de donner au maximum 50% de la mémoire RAM disponible à Elasticsearch, le reste étant dévoué à Lucene et au bon fonctionnement du système. Dans notre installation dont nous parlerons plus en détail ultérieurement, nous avons choisi de nous réserver une bonne marge de manœuvre puisqu'un Redis et un Logstash minimalistes tournent en sus sur la machine hébergeant Elasticsearch.

Cependant cette valeur de 50% n'a de sens que si Elasticsearch consomme moins de 32Go de RAM, en effet, en allouer plus devient contreproductif puisque jusqu'à 32Go la machine virtuelle Java (JVM) *compresse* les adresses des pointeurs, (tant qu'on reste sous la limite des 32Go de RAM on peut continuer à utiliser les adresses mémoires sur 4 octets), après, la consommation de mémoire explose et le *garbage collector* devient bien moins efficace.

Pour les machines possédant une énorme quantité de mémoire RAM (128Go à 1To) il conseille pour optimiser le fonctionnement de la machine de faire tourner plusieurs nœuds d'Elasticsearch dessus (attention aux entrées/sorties et à l'utilisation processeur).

9.5.2 Faire du nettoyage régulièrement

Plus Elasticsearch agrège des données plus il s'empâte, ce phénomène est inévitable sur le long terme. Les contre-mesures sont de *scale-out* (monter à l'échelle horizontalement) en rajoutant de nouveaux nœuds à notre cluster Elastic Search. On s'appliquera à manager les shards de façon optimisée bref à faire du *fine tuning*.

Pour éviter ce ralentissement la solution la plus radicale reste de supprimer les données. Justement, dans le cadre de notre projet, nous n'avons pas besoin de conserver toutes les données sur le long terme. Nous avons donc décidé de supprimer les logs de changement d'état des pare-feu tous les 4 jours. Ces logs peuvent représenter jusqu'à 30Go de données journalières. Pour ce faire nous utiliserons un tâche **cron** couplé à un script bash 15.1 tirant parti de l'API d'Elasticsearch dont nous parlerons plus bas. Pour indication, les index de firewall sont supprimés tous les 4 jours, (une requête judiciaire/alerte sécurité arrive en général en moins de 3 jours).

Les logs sont de toute façon également conservés ailleurs pour se soumettre aux impératifs judiciaires. Les index d'état (intéressants pour établir des statistiques) sont conservés 1 mois.

Remarque sur la commande `curl` et son utilisation dans `cron`

```
1 curl -sS -XDELETE $blade:$port/$target-$d
```

Listing 9.2 – Extrait de notre script 15.1

On remarque ici l'utilisation de l'option `-sS` pour *silent*, *Show errors*. Ainsi `cron` n'est pas importuné par les retours sur la sortie standard cela permet également, en ajoutant la directive **MAILTO : mail@example.fr** de renvoyer la sortie d'erreur vers mail@example.fr. Cela nécessite évidemment d'avoir configuré un serveur mail sur notre machine, par défaut sur Debian, Exim (`dpkg-reconfigure exim-config`).

Concernant `-XDELETE` c'est une utilisation de l'API REST décrite plus bas.

5. https://www.elastic.co/guide/en/elasticsearch/guide/current/_limiting_memory_usage.html

Une des stratégies préconisé dans le cas où l'on souhaite conserver des données sur le long terme alors qu'on en a seulement un besoin d'accès et d'analyse ponctuel ; consiste à les enregistrer dans des fichiers séparés (output Logstash) et de les faire ingérer à un cluster Elasticsearch dimesinonné en conséquence le moment venu.

9.6 Les API Elasticsearch

Elasticsearch est énorme, mais être assez facilement utilisable par le plus grand nombre, des API *optimisées* pour chaque tâches ont été conçues.

9.6.1 API REST

Cette API sert à la communication avec Elastisearch, comme toutes les API REST elle utilise les méthodes HTTP, ici : GET, POST, PUT et DELETE et s'appuie ensuite sur l'architecture d'Elasticsearch.

http `://host :port/[index]/[type]/[_action/id]`

Imaginons que dans un projet fictif, nous souhaitons référencer des tweets. On pourrait procéder comme suit pour ajouter le premier.

PUT `http ://100.127.255.1 :9200/twitter/tweet/1`

```
1 curl -XPUT http://100.127.255.1:9200/twitter/tweet/1
```

Listing 9.3 – Avec curl

Voici le résultat en utilisant curl, directement en ligne de commande, par navigateur, ...

```
1 PUT /twitter/tweet/1
```

Listing 9.4 – Avec Sense

Voici la syntaxe que nous obtiendrions en utilisant Sense, puisque notre serveur et notre port sont déjà renseignés, la syntaxe est bien plus courte.

La directive PUT est utilisé pour renseigner de nouvelles informations dans Elasticsearch.

Dans notre projet d'analyse de logs, il est fréquent que nous dussions supprimer des index, notamment dans le cas du paramétrage des *mappings*, mais également pour soulager notre infrastructure du poids des logs de firewall (20-30Go/jours).

DELETE `http ://100.127.255.1 :9200/twitter/`

Si nous avons un index twitter journalier il serait possible d'utiliser une commande très similaire pour supprimer tous les indexs d'un seul coup :

DELETE `http ://100.127.255.1 :9200/twitter*`

La directive DELETE est utilisé pour supprimer des informations d'Elasticsearch.

Enfin la directive GET qui sert à récupérer des information, à tout niveaux, index, type, mapping, type par défaut ..., en revanche il faut avoir un identifiant exact, ce n'est pas un outils de recherche (abordé dans la section suivante).

GET `http ://100.127.255.1 :9200/twitter/tweet/1`

Les information récupérées le sont en JSON.

9.6.2 Les API de recherche

DSL pour Domain Specific Language, parce que Elasticsearch est avant tout un moteur de recherche, il dispose de puissantes fonctionnalités de recherche. Il dispose donc de son propre langage d'interrogation le QueryDSL. C'est loin d'être un cas unique, par exemple Puppet dispose également de son propre langage de configuration.

Il existe plusieurs API (ou méthodes) de recherche dans Elasticsearch nous les détaillerons plus en détail après avoir expliqué le fonctionnement général d'une recherche dans Elasticsearch.

La recherche dans Elasticsearch est particulièrement efficace, car Elasticsearch indexe tout le contenu de ses documents (il indexe chaque field, en fonction d'un mapping (discuté plus bas)). C'est pour permettre l'indexation qu'Elasticsearch utilise du JSON structuré.

Empty Search

C'est la forme la plus basique de l'API de recherche, on ne spécifie pas de requête spécifique. Comprendre le fonctionnement et les possibilités de cette API basique permettra d'utiliser plus efficacement SearchLite, qui en est l'évolution directe.

```
1 GET /_search
```

Listing 9.5 – le "Hello World" de la recherche

Cette requête retourne tous les documents, de tous les index du cluster duquel nous sommes membre.

```
1 {
2   "took": 798,
3   "timed_out": false,
4   "_shards": {
5     "total": 201,
6     "successful": 201,
7     "failed": 0
8   },
9   "hits": {
10    "total": 353585048,
11    "max_score": 1,
12    "hits": [
13      {
14        "_index": ".kibana",
15        "_type": "visualization",
16        "_id": "Top5-nat-firewall-router",
17        "_score": 1,
18        "_source": {
19          "title": "Top5 nat-firewall router",
20          "visState": "{\n\"type\": \"histogram\", \"params\": {\n
          \"shareYAxis\": true, \"addTooltip\": true, \"addLegend
          \": true, \"mode\": \"stacked\", \"defaultYExtents\":
          false}, \"aggs\": [\n\"id\": \"1\", \"type\": \"count
          \", \"schema\": \"metric\", \"params\": {}}, {\n\"id
          \": \"2\", \"type\": \"terms\", \"schema\": \"group
          \", \"params\": {\n\"field\": \"IPnat\", \"size\": 5, \"
          order\": \"desc\", \"orderBy\": \"1\"}], \"listeners
          \": {}\",
21          \"description\": \"\",
22          \"version\": 1,
23          \"kibanaSavedObjectMeta\": {
24            \"searchSourceJSON\": \"{\n\"index\": \"firewall-*\", \"
            query\": {\n\"query_string\": {\n\"query\": \"*\", \"
            analyze_wildcard\": true}}, \"filter\": []}\"
25          }
26        },
27      },
28      .... 9 Autres ...

```

```

29 }
30 }

```

Listing 9.6 – Réponse type à notre requête précédente

Quelques explications :

hits L'élément `hits` contient des informations sur la requête et les réponse à la requête. *total* représente le nombre total de documents retournés pour cette requête, ici le nombre total de documents indexés : 353585048. Cela signifie qu'au moment de la requête il y avait environ 353 millions de lignes de logs indexés dans notre Elasticsearch au moment de la requête.

Les réponses à la requête nous sont renvoyées dans l'array *hits*, par défaut seul les 10 premiers documents satisfaisant notre requête nous sont renvoyés (comme il n'y avait pas de requête, simplement les 10 premiers documents).

Les documents renvoyés dans l'array sont classés en fonction de leur `_score`, une fois encore, puisque nous n'avons rien précisé dans notre requête, tous les résultats nous sont renvoyés avec le score 1.

On notera que le **max_score**, score maximum obtenu lors de la requête.

Enfin on remarque que le `source` (tous les champs indexés) de chaque document est présent dans la réponse à la requête.

took Took est le temps en millisecondes pris pour effectué cette requête, ici 798

shard L'élément `_shards`, nous indique le nombre de shards utilisé lors de la requête. Dans combien de shards tout c'est bien passé, dans combien il y a eu des erreurs, les erreurs sont très peu probables, cela se produit généralement sur un cluster de plusieurs machines, lorsque plusieurs d'entre elles sont inacessibles (il faut que les `primary` et `replica` d'un shard soient inacessible en même temps).

timeout Il est possible d'effectuer une recherche *par timeout*, cela signifie que Elasticsearch va effectuer sa recherche de façon classique, mais que lorsque le temps nécessaire à la recherche dépassera un temps déterminé, il renverra les informations qu'il a eu le temps de rassembler, toujours dans l'ordre qui lui semble le plus pertinent (ordonné par score). Attention cependant, cela ne nous absouds pas pour autant du coût de la recherche. Si les shards renvoient bien les résultats pertinents au moment souhaité, cela n'arrête pas pour autant la requête qui finira de s'exécuter en arrière plan.

```

1 GET /_search?timeout=10ms

```

Listing 9.7 – Une recherche "vide" avec timeout

Recherche multi-index et multitype La recherche multi-index et multitype est toujours possible comme dans l'API REST

```

1 GET /gb,us/_search
2 GET /g*,u*/_search
3 GET /gb,us/user,tweet/_search

```

Listing 9.8 – Une recherche multi-index ...

Pagination Par défaut lors d'une requête Elasticsearch renvoie seulement les 10^{ers} résultats. Il est biensure possible de paramétrer cela, pour afficher plus de résultats, et pas forcément les plus pertinents (ceux qui présente le score le plus élevé).

size permet d'indiquer le nombre de résultats souhaités

from permet d'indiquer le nombre de résultats que l'on souhaite sauter.


```
1 GET /_search?size=5&from=10
```

Listing 9.9 – Pagination

Search Lite

Comme expliqué avant il existe deux forme d'API de recherche. L'API lite avec requête en chaîne de caractères (*string query*) et l'API "*full body request*", qui nécessite comme corps de la requête, du JSON.

Pour utiliser la recherche SearchLite, nécessite simple d'ajouter en sus de notre empty search `?q=` et la requête. Attention si vous utilisez cette API avec curl il pourrait être nécessaire d'utiliser la syntaxe http (%2B pour + par exemple).

```
1 GET /_search?q=epinal
2 GET /state-2015.05.22/_search?q=epinal
```

Listing 9.10 – Exemples simples

Ici on cherche le terme *epinal* dans tous les champs, c'est par fois utile, mais dans de nombreux cas nous connaissons déjà le nom du champ (cf Logstash) dans lequel nous souhaitons avoir le terme.

Pour se faire il suffit d'utiliser la syntaxe suivante :

```
1 GET /_search?q=logsource:epinal
```

Listing 9.11 – Choix du champ

Bien plus intéressant, il est possible d'imposer des conditions à remplir ie : doit contenir le terme suivant, ou au contraire ne doit **pas** contenir le terme suivant.

```
1 GET /_search?q=+logsource:*epinal* -logsource:sw*
```

Listing 9.12 – Conditions must (not) match

Dans l'exemple précédant on souhaite chercher les équipement réseaux situés à epinal mais pas les switches. L'utilisation des + et - change vraiment le sens de la requête, dans la précédente sans les symboles, la présence ou non augmentait la pertinence des réponses contenant le terme recherché, mais n'était pas discriminante. Avec ces symboles, on exclu les réponses qui ne se conforment pas à nos exigences.

La présence des * sera explicité dans la partie sur la recherche full text (*prise d'Aspirine™conseillée*).

Il existe un autre moyen d'influencer la pertinence des résultats (de faire remonter en haut de liste ce qui nous intéresse le plus). Cela est particulièrement pratique dans les longues requêtes. Il s'agit de l'opérateur ^ qu'on n'utilise en général en conjonction de parenthèses (qui servent simplement à faire des groupes).

```
1 GET /_search?q=+logsource:*epinal* -logsource:sw* (timestamp:May)^10
   Power
```

Listing 9.13 – Modifier la pertinence

Dans cette requête nous cherchons toujours des équipements non switch situés à Epinal. Nous sommes cette fois ci très intéressés par ce qui s'est passé en Mai et d'autant plus si cela concerne un problème d'alimentation électrique.

Concernant la gestion du temps, et des timestamp, nous allons voir une propriété intéressante d'Elasticsearch lorsque le mapping de l'index est bien réalisé. Il est capable de *s'orienter* dans le temps à partir d'un champ texte. Cela n'est pas forcément très utile si l'on utilise Kibana, puisque son interface nous permet très facilement d'être plus précis, mais cela laisse imaginer les possibilités d'Elasticsearch.

```

1 GET /_search?q=+logsource:*epinal* -logsource:sw* (timestamp:>Jun)^10
   Power
2 GET /_search?q=+logsource:*epinal* -logsource:sw* (timestamp:=<Jun)
   ^10 Power

```

Listing 9.14 – Le temps dans SearchLite

SearchLite accepte les opérateurs `<>=<=>` et Elasticsearch est capable de les interpréter pour peu que le champ soit *mappé comme date* (cf Mapping).

Il est possible d'utiliser les opérateurs logiques **OR** et **AND** dont l'utilisation est assez évidente

...

```

1 +IPoutside:"8.8.8.8" +IPnat:"8.8.4.4" +(portnat:"37657" OR portnat
   : "19474")

```

Listing 9.15 – Opérateurs logiques

Il faut faire attention à l'utilisation des symboles `-`, `:`, `/`, qui ont une signification.

Remarque générale, les syntaxes présentées jusqu'à présent sont utilisables telles quelles dans Sense, et en retirant `GET /_search?q=` dans Kibana.

Full-Body Search et QueryDSL

9.7 Le mapping et l'analyse

9.7.1 Mapping

Le mapping est strictement comparable au schéma d'une base, dans le modèle relationnel. Le mapping définit donc le "type" de nos "champs", attention on fait rentrer dans le mapping plus que dans le schéma d'une base (analyse, indexation, ...).

Il y'a un mapping différent par index (il existe aussi des templates, applicable à plusieurs index). Pour accéder au mapping d'un index il suffit dans Sense de lancer la requête suivante.

```

1 GET /firewall-2015.05.07/_mapping

```

Listing 9.16 – Obtenir un mapping

Et voici un résultat :

```

1 {
2   "firewall-2015.06.10": {
3     "mappings": { "syslog": { "properties": {
4       "@timestamp": {
5         "type": "date",
6         "format": "dateOptionalTime"
7       },
8       "@version": {
9         "type": "string"
10      },
11      "IPinside": { "type": "string"},
12      "IPnat": { "type": "string"},
13      "IPoutside": { "type": "string"},
14      "action": { "type": "string"},
15      "chiffre": { "type": "integer"},
16      "datetest": {
17        "type": "string",
18        "index": "not_analyzed"
19      },
20      "firewall": { "type": "string"},
21      "host": { "type": "string"},
22      "information": { "type": "string"},

```

```
23         "logsource": {
24             "type": "string",
25             "index": "not_analyzed"
26         },
27         "message": {"type": "string"},
28         "numero": {"type": "string"},
29         "operation": {"type": "string"},
30         "portin": {"type": "string"},
31         "portnat": {"type": "string"},
32         "portout": {"type": "string"},
33         "program": {"type": "string"},
34         "reste": {"type": "string"},
35         "tags": {"type": "string"},
36         "timestamp": {"type": "string"},
37         "type": {"type": "string"}
38     }
39 }
40 }
```

Listing 9.17 – Exemple de mapping

On remarque que beaucoup de champs ont pour type **string**, c'est le type choisi par défaut.

Bien qu'ils ne soient pas utilisés ici il existe d'autres types de base, il est aussi possible d'en définir soi-même, cela ne sera pas abordé dans ce rapport.

Types par défaut :

- **boolean** : true/false
- **long** : nombres entiers
- **double** : nombres à virgule
- **string** : chaîne de caractères
- **date** : une date valide, (voir la doc pour les normes acceptées)

Pour créer un nouveau mapping, il faut au préalable supprimer le précédent, (supprimer l'index auquel est attaché le mapping).

9.7.2 Analyse

On remarque que certains champs ont également un **index** : **"not_analyzed"**. Tous n'en n'ont pas car il est souvent plus intéressant d'avoir des champs analysés. Et par défaut les champs sont analysés.

Il existe trois niveaux d'indexation :

- **Analyzed**, signifie que la chaîne de caractère est analysé puis indexé, donc cherchable en *full text*.
- **not_analyzed**, le champ est toujours cherchable, mais puisqu'il n'a pas été analysé, on ne peut le trouver qu'avec sa valeur exact. *Cette propriété peut se révéler essentielle pour réaliser des graphiques efficaces*. Il faut parfois savoir comment on veut exploiter ses données pour pouvoir les traiter en conséquence.
- **no**, n'index pas ce champ, il n'est pas cherchable. Je ne me suis jamais servi de cette propriété, peut sans doute avoir une utilité pour l'optimisation de performances.

Fonctionnement de l'analyse

Full text

Chapitre 10

Kibana



10.1 Qu'est ce que Kibana

Kibana est à la fois un front-end à Elasticsearch mais également un outil de présentation de données puissant. Kibana permet aussi dans une certaine mesure de faire du monitoring. (avec de grosses guillemets quand même)

Il est principalement codé en angularJS.

C'est l'outil de visualisation officiel d'Elasticsearch, il est assez ergonomique et donc plutôt facile d'utilisation. Sa barre de recherche utilise la syntaxe search Lite présenté plus dans le chapitre traitant d'Elasticsearch. Son utilisation pour réaliser des tableaux, dashboard et autre camemberts est assez aisé une fois les principes de bases assimilés.

10.2 Installation de Kibana

L'installation de Kibana est relativement simple, il suffit de télécharger l'application compressé à l'adresse sur le site de <https://download.elastic.co/kibana/kibana/kibana-4.0.2-linux-x64.tar.gz>. On décompresse, on lance (**path/bin/kibana**), et c'est parti !

10.2.1 Paramétrage

Afin de pouvoir se connecter à Elasticsearch il faut tout de même renseigner **path/config/kibana.yml** notamment : *port* (par défaut 5601), *host* (ip d'écoute) et surtout *elasticsearch_url*. Dans des circonstances normales c'est tout ce que vous aurez à paramétrer (hors SSL ...).

Il peut arriver dans de rares cas (lorsque Elasticsearch est saturé ou bien lors d'une requête particulièrement gourmande) que kibana se ferme car Elasticsearch met trop de temps à répondre. Il est dans ces cas là, il est fortement conseillé de redémarrer l'instance en question, d'étendre sa *HEAP_SIZE*, ou bien si possible, rajouter de la RAM.

Il est possible de modifier le *requestTimeout* dans **path/src/lib/waitForEs.js** C'est pour l'instant la seule façon de faire, d'après une issue github, la prochaine mouture de kibana devrait intégrer ce paramètre dans son fichier de configuration.

10.3 Utilisation de Kibana

Dans cette partie nous allons faire une brève présentation (illustré) de Kibana et de son fonctionnement.

10.3.1 Recherche

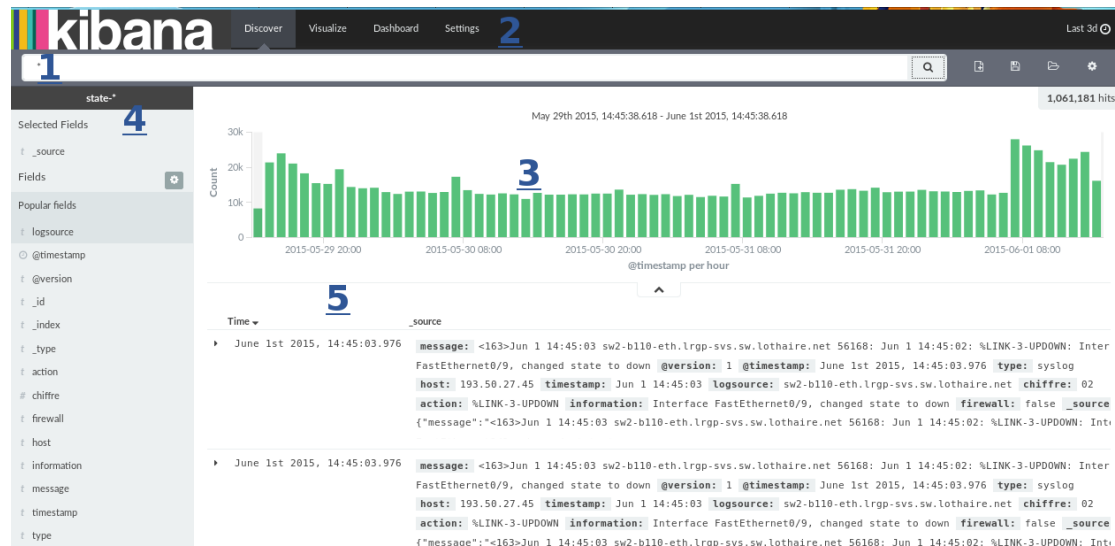


FIGURE 10.1 – Présentation générale de Kibana

Voici la page principale sur laquelle on arrive lorsque l'on se connecte à Kibana depuis son navigateur.

1. La barre de recherche (syntaxe SearchLite)
2. Barre de sélection des *modes* (Discover : Recherche, Visualize : Création de Tableaux et autre représentations graphiques, Dashboard : Rassemblement de ces présentations, Settings : Paramétrage de certaines options)
3. Tableau graphique des résultats de recherche
4. Tableau des champs de l'index
5. Tableaux des lignes correspondant à la recherche



FIGURE 10.2 – Choisir son index pour une recherche

Pour effectuer une recherche, on doit choisir dans quels index, si il est possible de réaliser une recherche dans plusieurs index à la fois, il faut dans Kibana que ce soit des indexs disposant du

même mapping. Typiquement rangés par **nom-***. Pour choisir son index il faut *sélectionner la roue dentée à droite de la barre de recherche*.




FIGURE 10.3 – Choisir son intervalle de temps

Lorsque l'on effectue une recherche avec Kibana il est possible de choisir de façon très flexible son intervalle de temps (bouton de temps en haut à droite). Il est tout d'abord possible de choisir les possibilités du menu rapide, affichées dans l'image ci-dessus. Le choix est déjà assez exhaustif, mais il est également possible de se positionner relativement par rapport à maintenant. Par exemple rechercher parmi les 30 dernières secondes, ou bien les deux derniers mois (de la seconde à l'année). Il est également possible de choisir un intervalle de temps absolue, à la seconde près.

Enfin il est possible de rafraîchir ces données en choisissant un intervalle allant de 5 secondes à une journée (également désactivable).

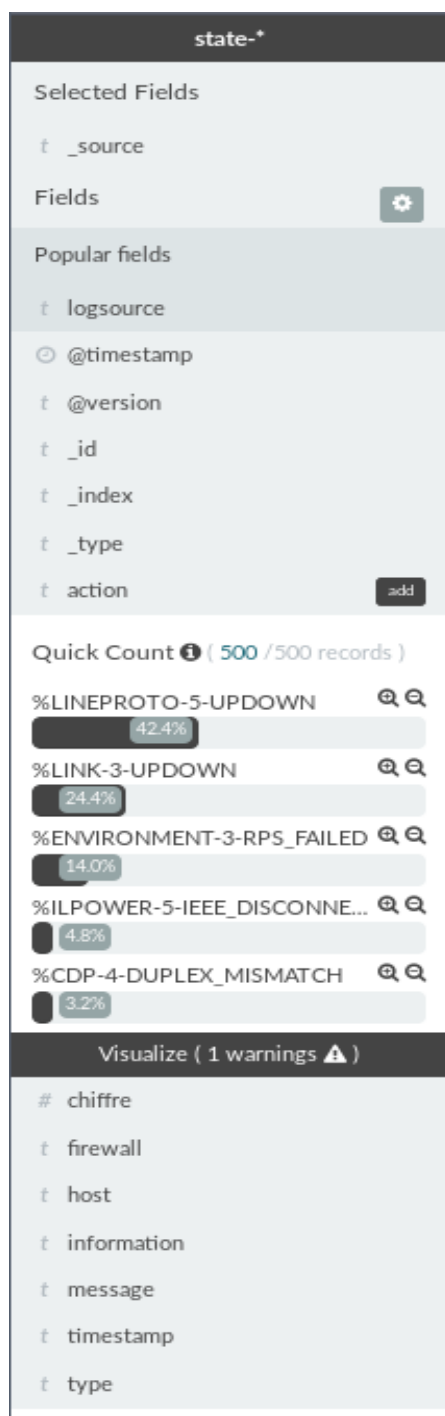


FIGURE 10.4 – Le tableau des champs

Le tableau des champs disponibles dans l'index est très pratique pour rendre plus lisible les informations que l'on recherche ainsi que pour obtenir des statistiques rapides sur les occurrences des termes les plus communs.

Ce tableau contient tous les champs disponibles dans l'index. Il est possible de faire de la ségrégation dans les résultats de nos recherches en incluant ou en excluant un ou plusieurs termes proposés (*on peut par exemple exclure le résultat le plus courant car on sait un switch défectueux, afin de se concentrer sur les autres pannes pas encore détectées et donc plus pertinentes*). Il suffit

pour cela d'appuyer sur les loupes situées à droite des termes suggérés.

Il est également possible de choisir de ne montrer que la ou les parties que l'on estime pertinente dans le log (en appuyant sur le bouton add à droite de chaque champ) et bien sure de combiner les deux dernières "techniques".



FIGURE 10.5 – Résultat

10.3.2 Visualization

Nous allons maintenant parler de la visualisation des données, il s'agit la encore que de donner un très bref aperçu des possibilités.

Create a new visualization Step 1

	Area chart Great for stacked timelines in which the total of all series is more important than comparing any two or more series. Less useful for assessing the relative change of unrelated data points as changes in a series lower down the stack will have a difficult to gauge effect on the series above it.
	Data table The data table provides a detailed breakdown, in tabular format, of the results of a composed aggregation. Tip, a data table is available from many other charts by clicking grey bar at the bottom of the chart.
	Line chart Often the best chart for high density time series. Great for comparing one series to another. Be careful with sparse sets as the connection between points can be misleading.
	Markdown widget Useful for displaying explanations or instructions for dashboards.
	Metric One big number for all of your one big number needs. Perfect for show a count of hits, or the exact average a numeric field.
	Pie chart Pie charts are ideal for displaying the parts of some whole. For example, sales percentages by department. Pro Tip: Pie charts are best used sparingly, and with no more than 7 slices per pie.
	Tile map Your source for geographic maps. Requires an elasticsearch geo_point field. More specifically, a field that is mapped as type:geo_point with latitude and longitude coordinates.
	Vertical bar chart The goto chart for oh-so-many needs. Great for time and non-time data. Stacked or grouped, exact numbers or percentages. If you are not sure which chart you need, you could do worse than to start here.

Or, open a saved visualization

Visualization Filter	manage visualizations
Adresses SNMP authfail	19 visualizations
camembert-logsource-state	

FIGURE 10.6 – Visualisations possibles

Voilà les différents types de visualisations parmi lesquelles nous pouvons faire notre choix. Toute ne conviennent pas, le meilleur choix est affaire d'expérience.




FIGURE 10.7 – Camembert de répartition des logs sur la dernière semaine

Voici un camembert très simple, réalisable en moins d'une minute. Il agrège les logs sur une semaine en les classant par date d'émission, groupés par jour. Il est évidemment possible de faire des choses plus compliquées avec plus ou moins données/de traitement.




FIGURE 10.8 – Camembert de répartition des logs sur 3 semaines

Il s'agit grosso modo des mêmes informations mais cette fois ci groupé par semaine par camembert, par jour dans le camembert interne, et par tranche de 3h sur l'anneau externe. Ces camemberts sont interactifs, on le verra dans la partie suivante sur les dashboards.

10.3.3 Dashboard

Présentons maintenant les dashboards. Sorte de tableaux virtuels, ils servent à rassembler les informations. Ces informations ont normalement plus de sens une fois mises cote à cote ou permette une analyse plus rapide d'une situation donnée.

La création de ces dashboards est également très simple, on en créer un nouveau en appuyant sur le plus à droite.

Il suffit ensuite de choisir les visualisation et ou les recherches enregistrées que l'on souhaite voir affiché.




FIGURE 10.9 – Choix des visualisations

Comme expliqué plus haut les visualisations ainsi que les tableaux sont interactifs. Il est par exemple possible de façon assez intuitive faire une recherche limitée ségréguée. Ici il suffit de cliquer sur le quartier désiré de la visualisation. Cela aura pour effet de faire apparaître la barre verte (contextuelle) et de ne faire apparaître dans le tableau de résultat à droite que les logs correspondants. Ici les logs ayant pour ip source affiché sur l'image.




FIGURE 10.10 – Dashboard simple

Il est également possible de facilement partager ces dashboard, via des liens avec iframes permettant de les inclure dans une page de monitoring par exemple.




FIGURE 10.11 – Dashboard plus avancé

10.3.4 Settings

Si un doute s'était imissé dans notre esprit, les paramètres de kibana, ne concernent uniquement kibana, pas Elasticsearch, certaines informations sont cependant affichées pour aider l'utilisation de kibana mais pas de possibilité de les modifier.

En revanche, il faut bien avouer que leurs consultation est plus agréable depuis kibana que depuis l'export json d'Elasticsearch.

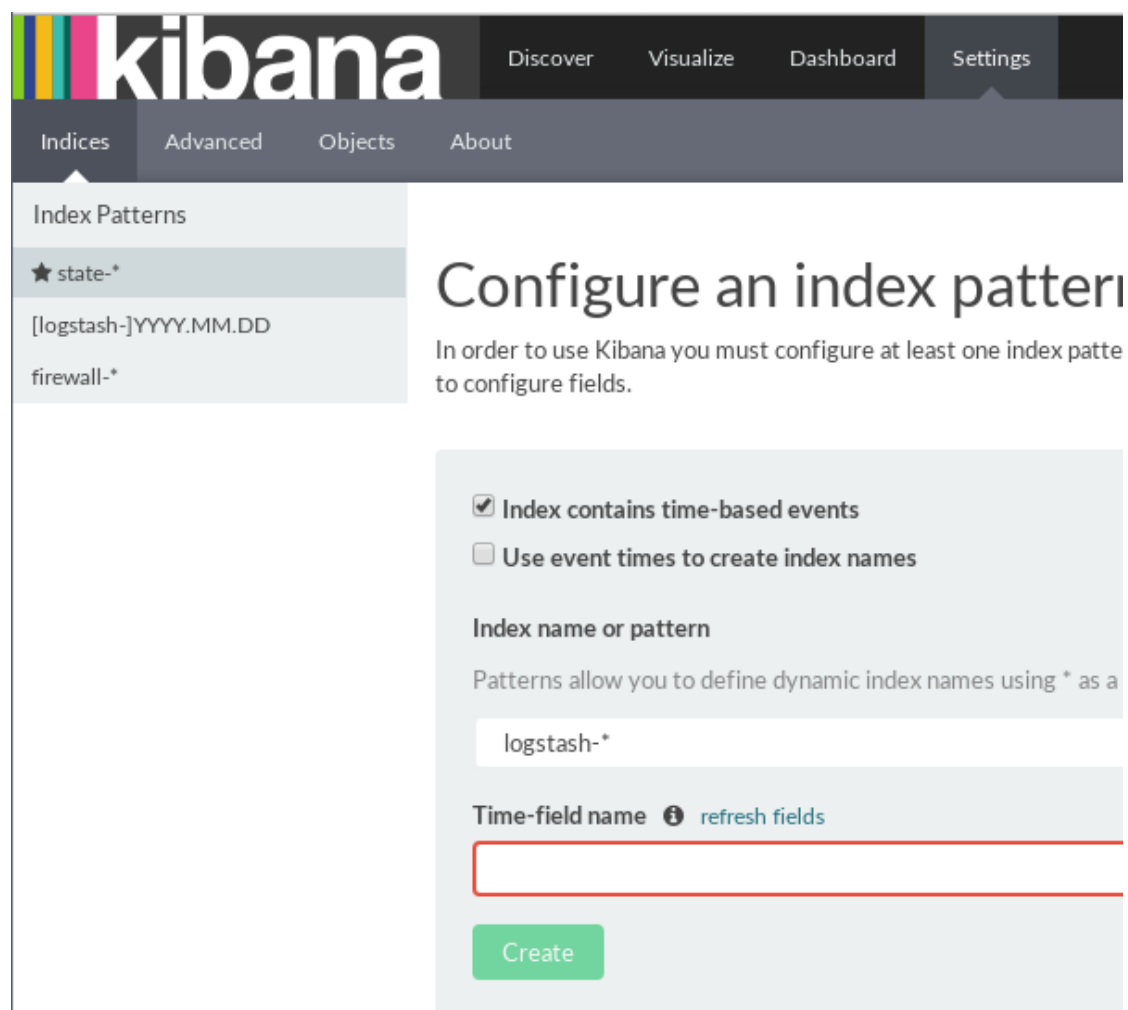
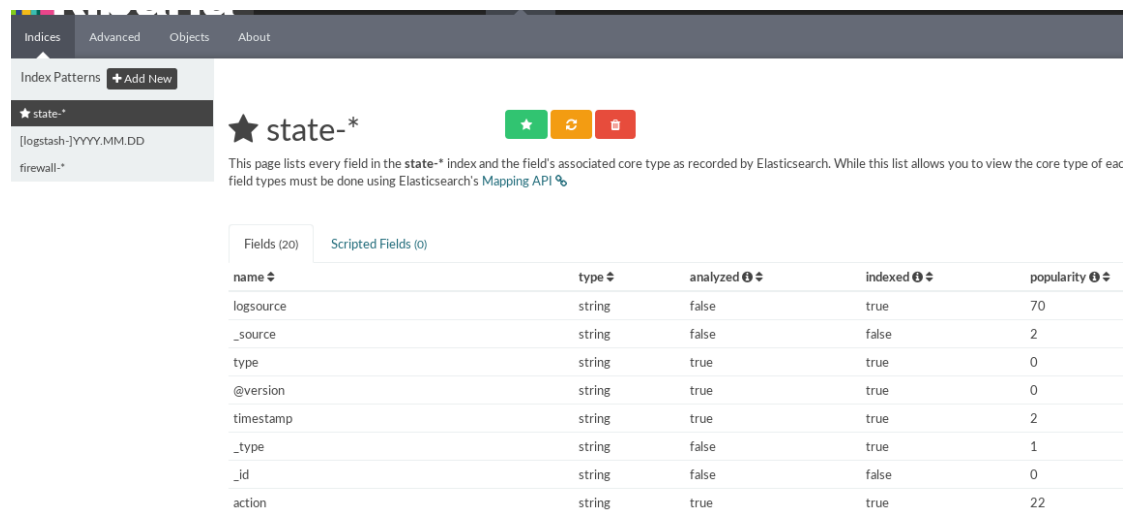


FIGURE 10.12 – Accueil de settings

Dans cette page vous pouvez créer de nouveaux ensembles d'index, ou en choisir un déjà existant.

En choisissant un index nous obtenons des informations sur son mapping, ce qui peut être utile pour effectuer des recherches plus pertinentes.



Indices | Advanced | Objects | About

Index Patterns [+ Add New](#)

- ★ state-*
- [logstash-]YYYY.MM.DD
- firewall-*

★ state-*

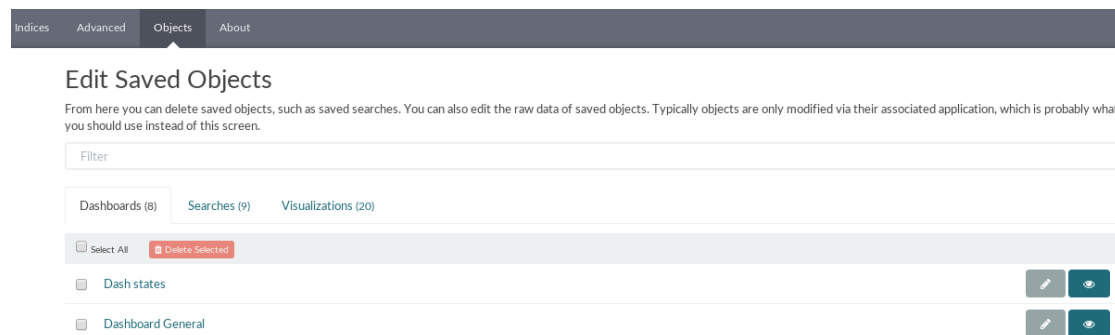
This page lists every field in the `state-*` index and the field's associated core type as recorded by Elasticsearch. While this list allows you to view the core type of each field, field types must be done using Elasticsearch's [Mapping API](#).

Fields (20) | Scripted Fields (0)

name ↕	type ↕	analyzed ↕	indexed ↕	popularity ↕
logsource	string	false	true	70
_source	string	false	false	2
type	string	true	true	0
@version	string	true	true	0
timestamp	string	true	true	2
_type	string	false	true	1
_id	string	false	false	0
action	string	true	true	22

FIGURE 10.13 – Mapping d'un index

Enfin, c'est aussi dans cette section que l'on a une liste et que l'on peut supprimer les objets enregistrés (recherche, visualisations, dashboard)



Indices | Advanced | Objects | About

Edit Saved Objects

From here you can delete saved objects, such as saved searches. You can also edit the raw data of saved objects. Typically objects are only modified via their associated application, which is probably what you should use instead of this screen.

Filter

Dashboards (8) | Searches (9) | Visualizations (20)

☐ Select All

<input type="checkbox"/> Dash states	<input type="button" value="Edit"/> <input type="button" value="Delete"/>
<input type="checkbox"/> Dashboard General	<input type="button" value="Edit"/> <input type="button" value="Delete"/>

FIGURE 10.14 – Liste des objets

Troisième partie

Synthèse et conclusion

Chapitre 11

Fonctionnement général

Chapitre 12

Évolutions possible

12.1 Monitoring

12.2 Sécurité

Chapitre 13

Conclusion

Quatrième partie

Annexes

Chapitre 14

Sources/Webographie/Bibliographie

Web

Introduction généraliste à ELK

<https://wooster.checkmy.ws/2014/04/elk-elasticsearch-logstash-kibana/>

Explications sur les moteurs d'indexation/elasticsearch

<https://zestedesavoir.com/articles/120/elasticsearch-maintenant-en-version-14/>

Articles sur les performances des SGBD vs moteurs d'indexation

<http://jolicode.com/blog/elasticsearch-comme-nouveau-standard-de-la-recherche-applicative>

Documentation de logstash générale

<http://logstash.net/docs/1.4.2/>

<http://logstash.net/docs/1.4.2/flags>

Installation de logstash

<http://www.elastic.co/guide/en/elasticsearch/reference/1.4/setup-repositories.html>

<https://github.com/elastic/logstash>

Debugger pour le filtre grok

<http://grokdebug.herokuapp.com/>

Documentation d'Elasticsearch

<http://www.elastic.co/guide/en/elasticsearch/reference/current/index.html>

<http://www.elastic.co/guide/en/elasticsearch/guide/current/index.html>

<http://www.elastic.co/guide/en/elasticsearch/reference/1.x/glossary.html>

Clustering Elasticsearch

<http://blog.trifork.com/2014/01/07/elasticsearch-how-many-shards/>

<http://stackoverflow.com/questions/12409438/when-do-you-start-additional-elasticsearch-nodes>

Documentation de Kibana

<http://www.elastic.co/guide/en/kibana/current/>

<https://github.com/elastic/kibana/tree/master/docs>

Livres

The logstash book

<http://www.logstashbook.com/>

Elasticsearch : The Definitive Guide

<http://shop.oreilly.com/product/0636920028505.do>

Rapport projet tutoré ASRALL sur les MOM

http://webloria.loria.fr/~lnussbau/ptasrall2015/rapport_a_mom.pdf

Vidéos

Conférence de Jean Baptiste Favre, architecte réseau blablacar, PSES 2014

<http://numaparis.ubicast.tv/videos/kibana/>

Vocabulaire de logstash <https://github.com/elastic/logstash/blob/f97c01da0631566e0ec07c9a076286e22a8f43a9/doc/glossary.asciidoc>

Chapitre 15

Code Source et scripts

```
1 #!/bin/bash
2 # -*- coding: utf-8 -*-
3 # Copyright (c) 2013, Frank Rosquin <frank@rosquin.net>
4 # ISC license
5 # Permission to use, copy, modify, and/or distribute this software
6 # for any
7 # purpose with or without fee is hereby granted, provided that the
8 # above
9 # copyright notice and this permission notice appear in all copies.
10 # Last Modified François Dupont 2015-05-28
11 blade="100.127.255.1"
12 daysback=31
13 port=9200
14 start_from=4
15 target="firewall"
16
17 while getopts b:d:p:s:t: option
18 do
19 case $option in
20     b)
21         blade=$OPTARG
22         ;;
23     d)
24         if [ $OPTARG -ge 0 ]; then
25             daysback=$OPTARG
26         else
27             echo "-d should be a number, 0 or more"
28             echo ""
29             print_usage
30         fi
31         ;;
32     p)
33         if [ $OPTARG -ge 0 ]; then
34             port=$OPTARG
35         else
36             echo "-p should be a number, 0 or more"
37             echo ""
38             print_usage
39         fi
40         ;;
41     s)
42         if [ $OPTARG -ge 0 ]; then
43             start_from=$OPTARG
44         else
45             echo "-s should be a number, 0 or more"
46             echo ""
47             print_usage
```

```
46         fi
47         ;;
48     t)
49         target=$OPTARG
50         ;;
51     \?)
52         print_usage
53         ;;
54 esac
55 done
56
57 end=$(expr $start_from \+ $daysback)
58 if [ $? == 0 ]; then
59     for i in $(seq $start_from $end); do
60         d=$(date --date "$i_days_ago" +"%Y.%m.%d")
61         curl -sS -XDELETE $blade:$port/$target-$d
62     done
63 else
64     echo "Invalid_number_of_days_specified,_aborting"
65 fi
66 curl -XPOST "$blade:$port/_optimize"
67
68 print_usage() {
69     echo "
70 Usage: _$_[OPTIONS]
71 Options:
72 -----b_blade_: name_or_ip_of_the_elasticsearch_server
73 -----default_: 100.127.255.1
74 -----d_daysback_: number_of_days/indexes_deleted_(from_start_day)
75 -----default_: 31
76 -----p_port_number
77 -----default_: 9200
78 -----s_start_number, _starting_delete_day_(-s_4_=if_we_are_the_30/04_
79         it_starts_deleting_from_26/04_included)
80 -----default_: 4
81 -----t_target_name_of_the_indices
82 -----default_: firewall
83 Example:
84 "
85     exit 0
86 }
```

Listing 15.1 – Script de suppression d'index

Glossary

API Une API, Application Programming Interface, est une interface permettant d'interagir avec un programme par l'intermédiaire d'"opérations simples". Elles sont en générale la pour faciliter la réutilisation d'un programme plus complexe. C'est parce que openstreetmap à une API que l'on a vu autant de logiciels utilisant ses cartes/tuiles.. 28

flag Un drapeau, dans la dénomination logstash, le flag représente une option passé en argument exemple : -w.. 15

fulltext Un drapeau, dans la dénomination logstash, le flag représente une option passé en argument exemple : -w.. 23

logs Un log c'est une buche !. 4, 6, 16

thread explication thread processus etc... 15